


Графы знаний

Представление знаний (англ. knowledge representation) направление в исследованиях искусственного интеллекта, посвящённое представлению информации о мире в форме, которую было бы возможно использовать в компьютерных системах для решения сложных прикладных задач.

Пример: диагностирование заболеваний или ведение диалога на естественном языке.

- 1960 г. – семантические сети
- 1980 г. – Гронингенский университет и университет Твенте начали работу над совместным проектом, названным "Графы знаний", базируясь на устройстве семантических сетей с рёбрами, ограниченными наперёд заданным количеством отношений - для упрощения алгебры на графах
- 2012 г. – Google представили свою версию графа знаний

Пример семантической сети



Knowledge Graph, или граф знаний, – семантическая сеть, в которой хранится информация о разных сущностях взаимосвязях между ними. Сущностью или «узлом» графа может быть что угодно: человек, предмет, дата, концепция и любой другой материальный объект или абстрактное понятие. Предикаты или «ребра» отражают

взаимосвязи и отношения между разными сущностями в графе. Например, Альберт Эйнштейн и город Ульм в Германии - две самостоятельные сущности, а тот факт, что Эйнштейн родился в Ульме, – будет уже предикатом.

Knowledge Graph помогают связать большое количество данных из разных источников в одну общую коллекцию знаний. Они могут быть общими, то есть хранить информацию о разных видах данных, и специализированными - фокусироваться на какой-то одной предметной области.

Например, Wikidata – один из самых крупных графов знаний – хранит разностороннюю информацию. BioPortal крупнейший специализированный граф с более чем 140 млрд фактов о биотехнологиях и медицине.

Число открытых Knowledge Graph в интернете растет, все вместе они образуют облако семантически связанных друг с другом данных - Linked Open Data Cloud.

Граф знаний Google

Используется Google и его службами для улучшения результатов поисковой системы с помощью информации, собранной из различных источников.

Граф знаний предоставляет структурированную и подробную информацию о теме в дополнение к списку ссылок на другие сайты. Цель состоит в том, что пользователи смогут использовать эту информацию для решения своих запросов без необходимости перехода на другие сайты и сбора информации самостоятельно. Например, при запросе «Леонардо Да Винчи» в правом углу будет отображена информация о художнике, краткие биографические данные, а также его картины, другие художники того же времени и т.д. При переходе на картину, для нее будет открываться своя расширенная страница, если информация о ней имеется в базе.

[Интерактивная карта открытых графов знаний различной тематики](#)

Графы и машинное обучение

<https://academy.yandex.ru/handbook/ml/article/grafovye-nejronnye-seti>

<https://deepschool-pro.notion.site/1665b8940c27431f95a801da2577c072>

Довольно много данных, имеющих графовую структуру:


- описания дорожных и компьютерных сетей,
- социальные графы и графы цитирований,
- молекулярные графы, а также графы знаний, описывающих взаимосвязи между сущностями, событиями и абстрактными категориями.

Молекулярный граф

Молекулярные графы – это пример графов с, как правило, средним количеством вершин и ребер; вершины и связи в молекулярных графах имеют признаковое описание

(типы атомов и ковалентных связей, а также информацию о зарядах и т.п.), но при этом также являются гомогенными графами.

(вершины - атомы, а ребра – ковалентные связи)



Графовые данные довольно разнообразны. Они могут отличаться между собой в следующих моментах:

- По размеру, т.е. количеству вершин и/или ребер.
- По наличию признаков описаний вершин и рёбер. В зависимости от решаемой задачи, графы могут содержать информацию только в вершинах, только в ребрах, либо же и там и там.
- Кроме того, графы могут быть **гомо-и гетерогенными** - в зависимости от того, имеют ли вершины и ребра графа одну природу либо же нет.

К классу гетерогенных графов относятся, например, **графы знаний**. Вершины (сущности) и связи (ребра) такого графа могут иметь различную природу: скажем, вершинами могут быть сотрудники и подразделения компании, а рёбра могут отвечать отношениям «X работает в подразделении Y», «X и Z коллеги» и так далее.

Социальный граф

Социальные графы содержат огромное количество вершин и ребер, часто измеряющееся в тысячах, содержат информацию в вершинах и очень редко в ребрах, а также являются гомогенными, так как все вершины имеют один тип.

Задачи на уровне всего графа

Прогнозирование свойства целого графа. Например, для молекулы, представленной в виде графа, мы можем предсказать ее потенциальное взаимодействие с рецептором, связанным с заболеванием или какие-то химический свойства.

Для изображений – задачи классификации изображения, для текста, например, определение тональности.

Задачи на уровне вершин

Связаны с прогнозированием свойств или роли каждой вершины в графе.

Например, предсказать интересы нового пользователя по интересам его друзей.

Классическим примером задачи прогнозирования на уровне вершин является "Каратэ-клуб Зака". Набор данных представляет собой единственный социальный сетевой граф, состоящий из лиц, которые присягнули на верность одному из двух каратэ-клубов. По легенде, конфликт между мистером Хай (инструктором) и Джоном А (администратором) вызвал раскол в каратэ-клубе. Вершины - это каратисты, а ребра - взаимодействия между этими каратистами за пределами каратэ. Задачей прогнозирования является классификация по тому, станет ли данный участник преданным мистеру Хай или Джону Х после конфликта. В данном случае расстояние от вершины до инструктора или администратора сильно коррелирует с этой меткой.

Задачи прогнозирования на уровне вершин идентичны сегментации изображений, где мы пытаемся присвоить класс каждому пикселю на изображении.

В случае текста, аналогичная задача – прогнозирование частей речи для каждого слова в предложении (например, существительное, глагол, наречие и т.д.).

Задачи на уровне ребер

Например, предсказания пропущенных связей в графе. В больших графах часто некоторые связи отсутствуют. Например, в социальном графе пользователь может добавить не всех знакомых в друзья. А в графе знаний могут быть проставлены только простые взаимосвязи, а высокоуровневые могут быть пропущены.

Оптимизация «классических» алгоритмов


Группа исследователей из университетов Синьхуа, Стенфорда и Института Макса Планка представили [детерминированный алгоритм](#) для решения задачи SSSP в ориентированных графах с неотрицательными вещественными весами, который работает за время, пропорциональное числу ребер, умноженному на логарифмический множитель, который растет медленнее, чем обычный логарифм.

Проблема поиска кратчайшего пути от одной вершины до всех остальных (SSSP) — одна из фундаментальных в теории графов, и её история тянется с 50-х годов прошлого века. Классический алгоритм Дейкстры, в связке с продвинутыми структурами данных, решает эту задачу за время, которое примерно пропорционально сумме числа ребер и произведения числа вершин на логарифм от их же числа.

Именно этот множитель — число вершин, умноженное на логарифм, долгое время считался теоретическим минимумом, так как в своей основе алгоритм Дейкстры побочно сортирует вершины по расстоянию от источника. Этот предел известен как «барьер сортировки» и казался непреодолимым.

Основные определения

Граф (простой) — пара $G = (V, E)$, где $V \neq \emptyset$ - конечное множество вершин, E — множество пар вершин. Если E — множество неупорядоченных пар вершин, то граф называется **неориентированным** (элементы множества E называют ребра), иначе — **ориентированным** (элементы множества E называют дуги). Возможность кратных ребер и петель — **мультиграф** (псевдограф).



Если есть ребро (x, y) , то вершины x, y - концевые, при этом говорят, что ребро *инцидентно* своим концевым вершинам. В неориентированном графе вершина y смежна с вершиной x , если существует ребро (x, y) . Отношение смежности для неориентированного графа симметрично: если x смежна с y , то y смежна с x . В

ориентированном графе вершина y смежна с вершиной x , если существует дуга (x, y) . В неориентированном графе степенью $deg(x)$ или валентностью вершины x называется количество ребер, инцидентных x . Если вершина имеет степень 0, то она называется **изолированной**. В орграфе различают входящую ($indeg(x)$) и исходящую ($outdeg(x)$) степень вершины.

Полезная литература

1. [Курс лекций по Графам Знаний \(Knowledge Graphs\)](#)

Используются в машинном обучении:

- Дополненное глубинное обучение для анализа тональности высказываний.
- Предоставление новостей, рекомендованных конкретному пользователю.
- Машинный перевод.
- Для предоставления рекомендаций.

2. [Как графы знаний и LLM могут друг другу помочь](#)

3. Применение нейронных сетей для анализа графов со свойствами гомофилии и гетерофилии (<https://habr.com/ru/companies/fa/articles/828172/>)

4. В теории, использование графовой структуры может помочь ML-модели в выучивании закономерностей, однако на практике очень сложно внедрить графы в продакшен из-за ряда проблем. В статье рассказано о внедрении графов в реальную социальную сеть, с какими сложностями столкнулись и что усвоили.

(<https://arxiv.org/abs/2402.11139>)

5. [Курс "Машинное обучение на графах"](#)

6. Графовые нейронные сети (в частности, решение задач комбинаторной оптимизации), графовые базы данных, марковские сети, байесовские сети, диаграммы влияния и многое другое... (Вырожденностные графовые модели. Принципы и приложения – Луис Энрике Сукар)

7. Книга "Графовые нейронные сети на Python" – Лабонн М., Груздев А.В.

8. Книга "Теория графов" – О. Оре, "Теория графов" – Ф. Харари

Д/з

1. Придумать по два примера гомо- и гетерогенного графа
2. Придумать когда граф содержит информацию только о вершинах, ребрах и там и там